D-Bot (DB-GPT): bác sĩ AI cho PostgreSQL

D-Bot là gì?

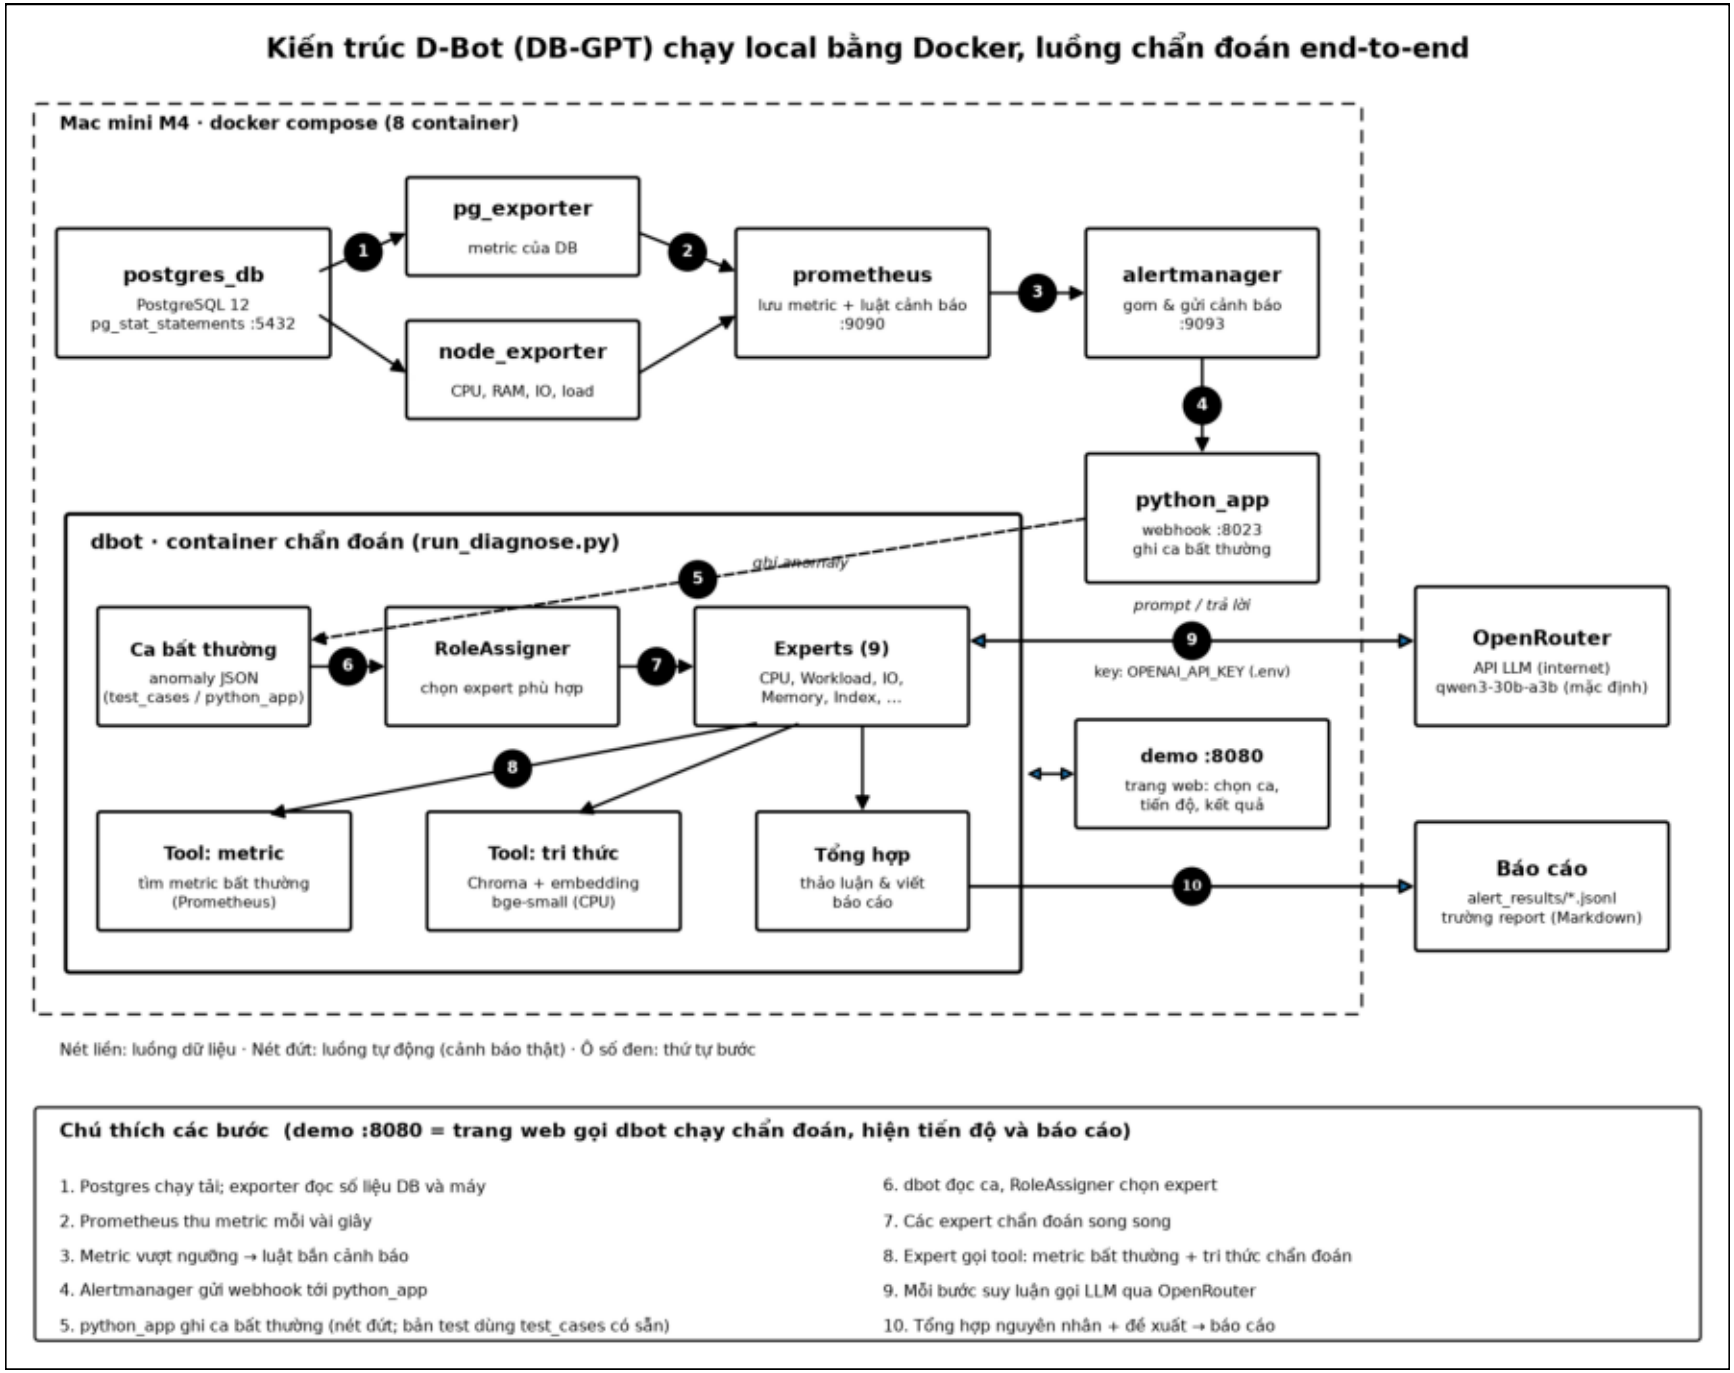
Khi database có cảnh báo (CPU cao, truy vấn chậm...), D-Bot cử một nhóm chuyên gia AI đọc chỉ số từ Prometheus, tra kho tri thức chẩn đoán, thảo luận với nhau rồi viết báo cáo: nguyên nhân gốc + cách khắc phục. Bản này chạy toàn bộ bằng Docker trên Mac mini M4, LLM gọi qua OpenRouter (không cần model local). Một lệnh: docker compose up -d --build.

8	5	~4–6 phút	$0.09–0.19	Qwen3-30B
service Docker	kịch bản sự cố mẫu	mỗi ca chẩn đoán	mỗi ca (OpenRouter)	model mặc định

Luồng: Cảnh báo → Phân công chuyên gia → Điều tra chỉ số + tri thức → Thảo luận → Báo cáo

Demo: mở http://localhost:8080, chọn kịch bản, xem tiến độ và kết quả (có chế độ xem lại, không tốn tiền).

Kiến trúc end-to-end



Các service và thành phần chính

Service	Cổng	Vai trò
postgres_db	5432	PostgreSQL 12 + pg_stat_statements, DB bị chẩn đoán
prometheus	9090	Thu metric, chạy luật cảnh báo
alertmanager	9093	Gom cảnh báo, gửi webhook
node_exporter	9100	Metric máy: CPU, RAM, IO, load
pg_exporter	9187	Metric PostgreSQL
dbot	–	Container chẩn đoán (run_diagnose.py)
python_app	8023	Webhook nhận cảnh báo, ghi ca bất thường
demo	8080	Trang web demo: chọn ca, tiến độ, kết quả

Thành phần trong dbot

- **Chuyên gia AI (multi-agent)** — RoleAssigner chọn expert: CPU, Workload, IO, Memory, Index...
- **Kho tri thức** — Chroma + embedding bge-small chạy local (CPU), không tốn API
- **Tools** — Tìm metric bất thường (Prometheus), tra tri thức, xem SQL chậm
- **Viết báo cáo** — Thảo luận bàn tròn → nguyên nhân gốc + đề xuất (Markdown)

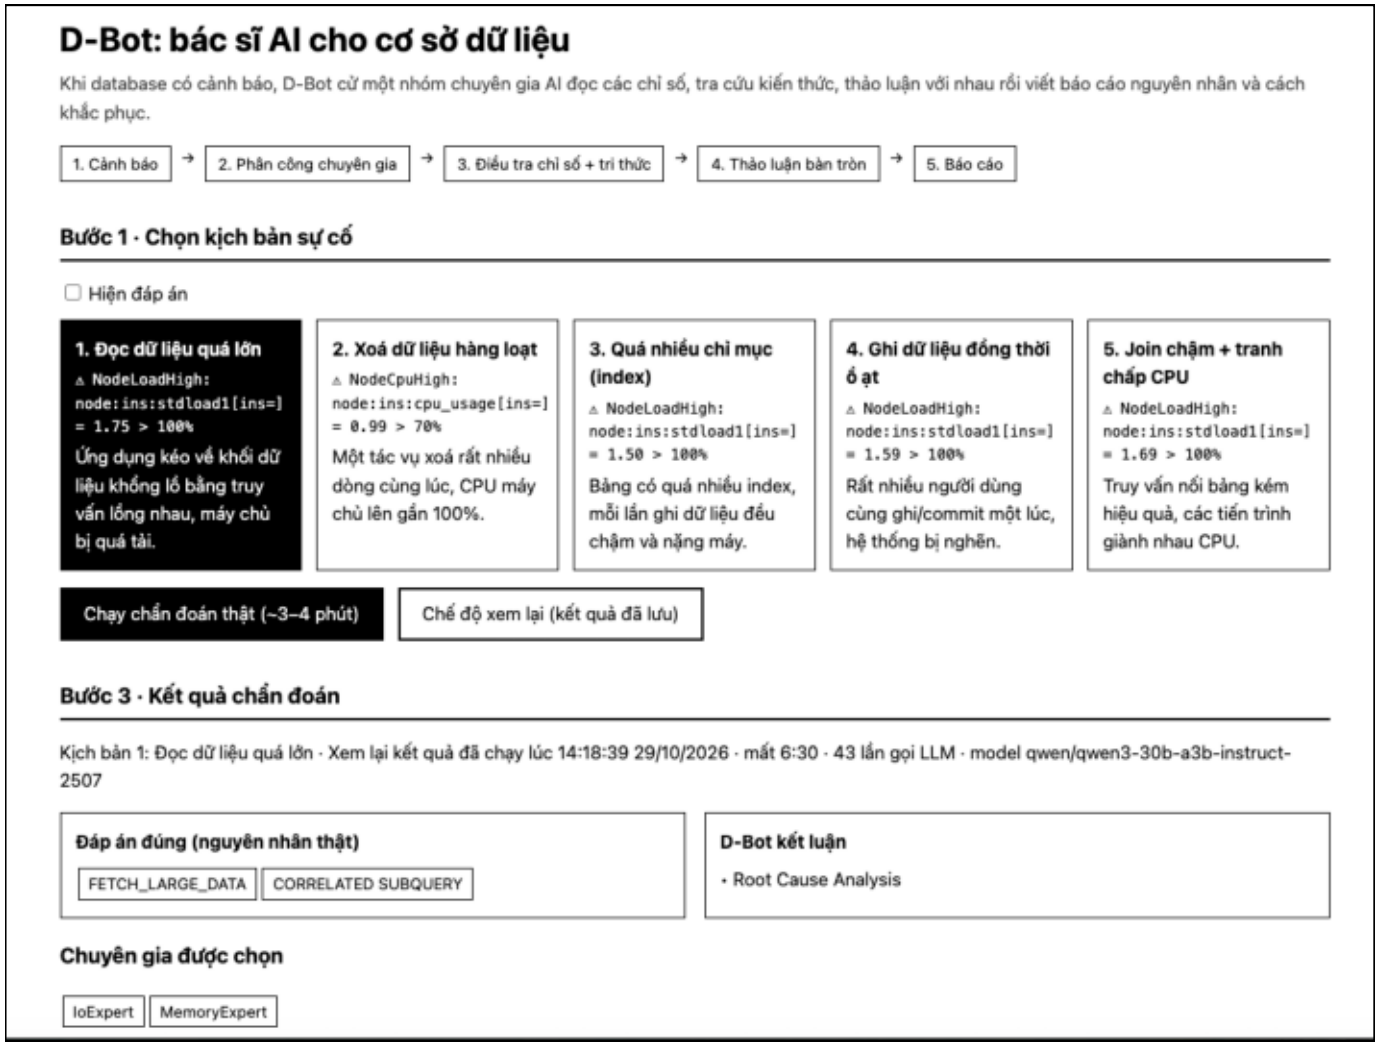
Trang demo :8080 (setup xong sẽ thấy)



① Chọn kịch bản



② D-Bot đang chạy (tiến độ, log)



③ Kết quả: đáp án đúng vs D-Bot kết luận, chỉ số, báo cáo

Kết quả chạy thử (sơ bộ)

Ca	Đáp án đúng	gpt-4o-mini	Qwen3-30B
1	Lấy dữ liệu lớn, subquery tương quan	Gần (chỉ subquery)	Đúng cả 2 ý
2	Xóa hàng loạt	Đúng	Đúng
3	Quá nhiều index	Gần	Gần
4	Insert/commit đồng thời	Gần	Gần
5	JOIN kém, tranh chấp CPU	Đúng	Đúng

• Sửa tra tri thức: ngưỡng tương đồng 0.4 quá chặt với bge-small → trước 0 tài liệu, nay 8–24 tài liệu/ca.

• Thời gian: 4o-mini ~2.5–5 phút/ca, Qwen3-30B ~4–5.5 phút/ca. Chi phí thực ~$0.09–0.19/ca.

• Qwen3-30B nhỉnh hơn 4o-mini ở ca 1, rẻ hơn (0.10/0.30 mỗi triệu token) → chọn làm mặc định.

• Lưu ý: đánh giá sơ bộ theo từ khóa trong báo cáo, mỗi ca chạy 1 lần; cần thêm lần chạy để kết luận.